Classificação e Agrupamento de Músicas

Uma Análise de Popularidade Baseada em Atributos Acústicos

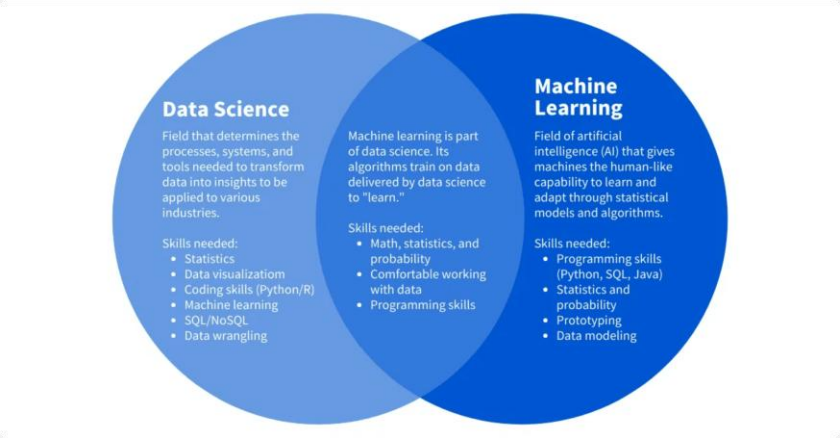

Disciplina

Técnicas Avançadas de Machine Learning

Aluno

Eduardo de Almeida Velocci

Data

Dezembro de 2025

Motivação e Questões de Pesquisa

O sucesso de uma música é um fenômeno complexo. A aplicação de Machine Learning permite analisar a relação entre características acústicas e o engajamento do público.

Questões de Pesquisa

1. Quais atributos acústicos são mais relevantes para a popularidade?
2. É possível prever a popularidade de uma faixa com base nesses atributos?
3. Existem grupos de músicas com características similares (clusters)?

Dataset e Análise Exploratória de Dados

Dataset

Contém atributos acústicos como **energy**, **danceability**, **loudness**, **acousticness**, **instrumentalness** e **tempo**.

Desafios Iniciais

- As variáveis apresentam **escalas de medição distintas**, exigindo padronização.
- Observa-se a presença de **outliers** em algumas distribuições, o que pode influenciar a performance dos modelos.

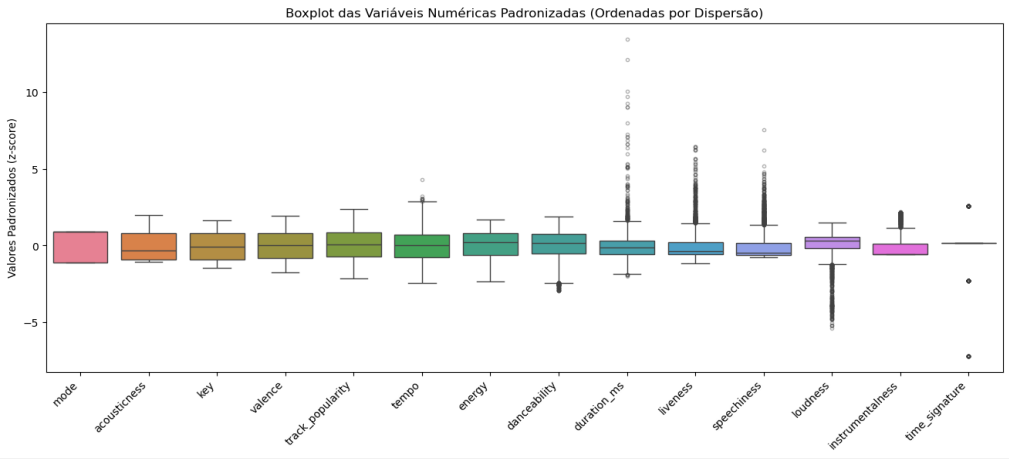


```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3370 entries, 0 to 3369
Data columns (total 22 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Unnamed: 0                3370 non-null   int64
 1   energy                    3369 non-null   float64
 2   tempo                     3369 non-null   float64
 3   danceability              3369 non-null   float64
 4   loudness                  3369 non-null   float64
 5   liveness                  3369 non-null   float64
 6   valence                   3369 non-null   float64
 7   speechiness               3369 non-null   float64
 8   instrumentalness          3369 non-null   float64
 9   mode                      3369 non-null   float64
 10  key                       3369 non-null   float64
 11  duration_ms               3369 non-null   float64
 12  acousticness              3369 non-null   float64
 13  track_name                3370 non-null   object
 14  track_artist              3370 non-null   object
 15  track_album_name          3369 non-null   object
 16  track_album_release_date  3370 non-null   object
 17  track_popularity          3370 non-null   int64
 18  time_signature            3369 non-null   float64
 19  type                      3369 non-null   object
 20  track_id                  3370 non-null   object
 21  track_album_id            3370 non-null   object
dtypes: float64(13), int64(2), object(7)
memory usage: 579.3+ KB
Número de observações: 3370
Número de variáveis: 22
```

Preparação dos Dados para Classificação

1 Variável Alvo

- Criação da variável binária de popularidade
- **Popular = 1** (se popularity > 70)
- **Não Popular = 0** (caso contrário)

2 Tratamento de Dados

- Identificação de valores ausentes
- Remoção ou imputação de **missing values**
- Garantia da integridade do dataset

3 Padronização

- Aplicação de **StandardScaler**
- Média zero e desvio-padrão um
- Equilíbrio entre variáveis

Modelos de Classificação

Modelos Utilizados

RF **Random Forest**

Robusto e eficiente na captura de relações não-lineares.

XG **XGBoost**

Algoritmo de *boosting* conhecido por sua alta precisão e otimização de desempenho.

Justificativa da Escolha

A escolha de modelos **ensemble** visa obter maior poder preditivo e estabilidade, minimizando o risco de *overfitting* em um problema de classificação binária.

Modelo	Acurácia	F1-Score	Gini
RF_FULL	0.7522	0.0234	0.5141
XGB_FULL	0.7448	0.181	0.4971
RF_REDUCED	0.7493	0.0765	0.4603
XGB_REDUCED	0.7522	0.2578	0.4571
RandomForest_Balanced	0.7018	0.4401	0.4481
XGBoost_Balanced	0.7187	0.4444	0.4836

Avaliação dos Modelos

Métricas de Avaliação

- **Acurácia:** Proporção de previsões corretas no conjunto de teste.
- **Gini (AUC Transformado):** Medida de discriminação, indicando a capacidade do modelo de separar classes.

Análise

A avaliação no conjunto de teste mostra que ambos os modelos apresentam desempenho semelhante, com acurácia em torno de 70%. XGBoost apresentou ligeira vantagem em termos de Gini, F1 indicando melhor capacidade de discriminação entre músicas populares e não populares.

“testei versões com GridSearch e conjuntos reduzidos”

Modelo	Acurácia	F1-Score	Gini
RF_FULL	0.7522	0.0234	0.5141
XGB_FULL	0.7448	0.181	0.4971
RF_REDUCED	0.7493	0.0765	0.4603
XGB_REDUCED	0.7522	0.2578	0.4571
RandomForest_Balanced	0.7018	0.4401	0.4481
XGBoost_Balanced	0.7187	0.4444	0.4836

Avaliação dos Modelos

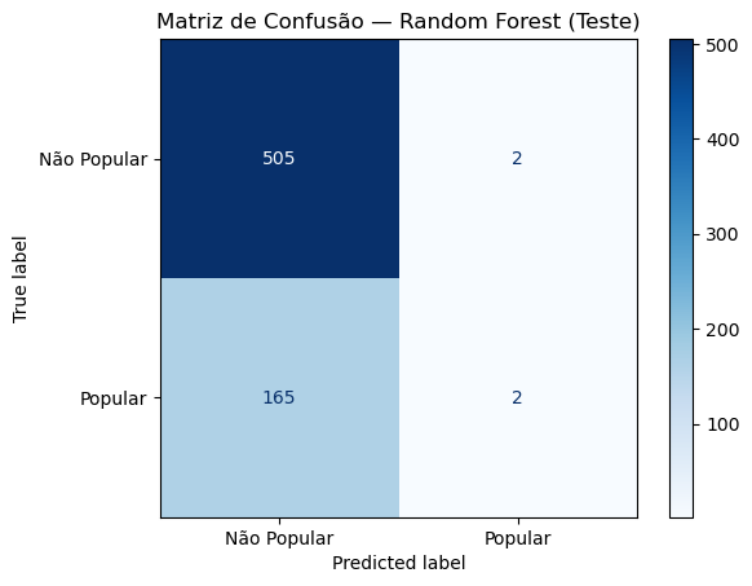

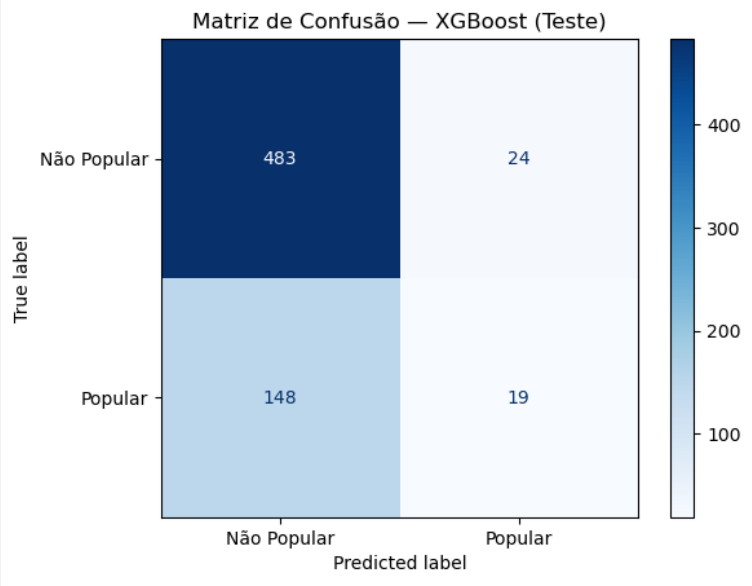

O XGBoost apresentou melhor desempenho que o Random Forest na identificação de músicas populares, embora ambos os modelos ainda tenham dificuldade devido ao desbalanceamento da base e à complexidade do fenômeno da popularidade musical.

Avaliação dos Modelos Balanceados

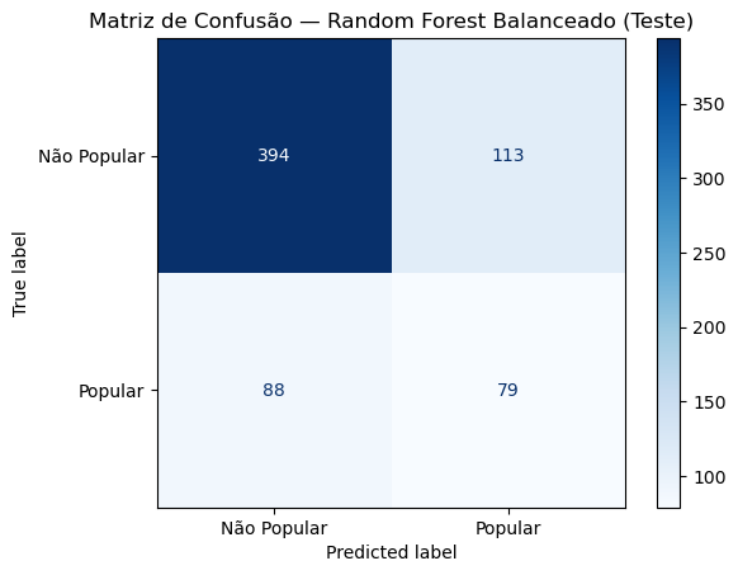

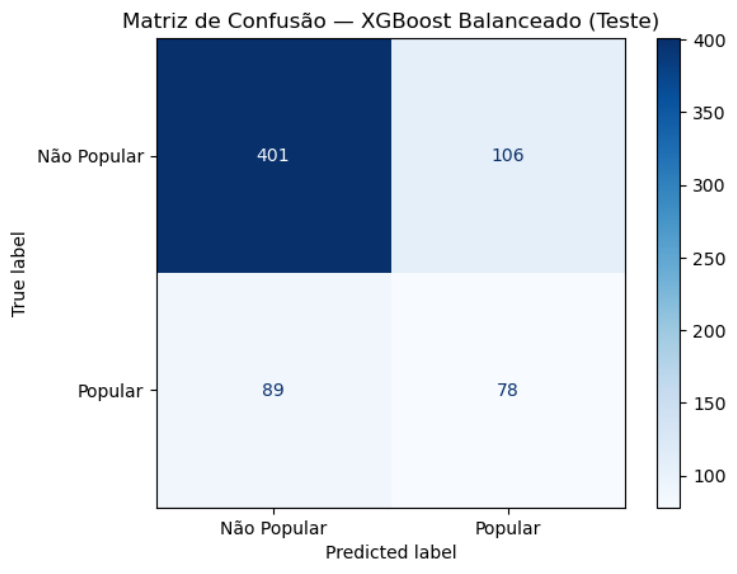

As matrizes de confusão demonstram o impacto positivo das técnicas de balanceamento aplicadas. Ambos os modelos agora apresentam capacidade de identificar músicas populares, com o XGBoost Balanceado alcançando 78 acertos na classe "Popular" (47% de recall) e o Random Forest Balanceado 79 acertos (47% de recall), representando melhoria substancial em relação aos modelos originais.

Robustez dos Modelos em Diferentes Tamanhos de Amostra

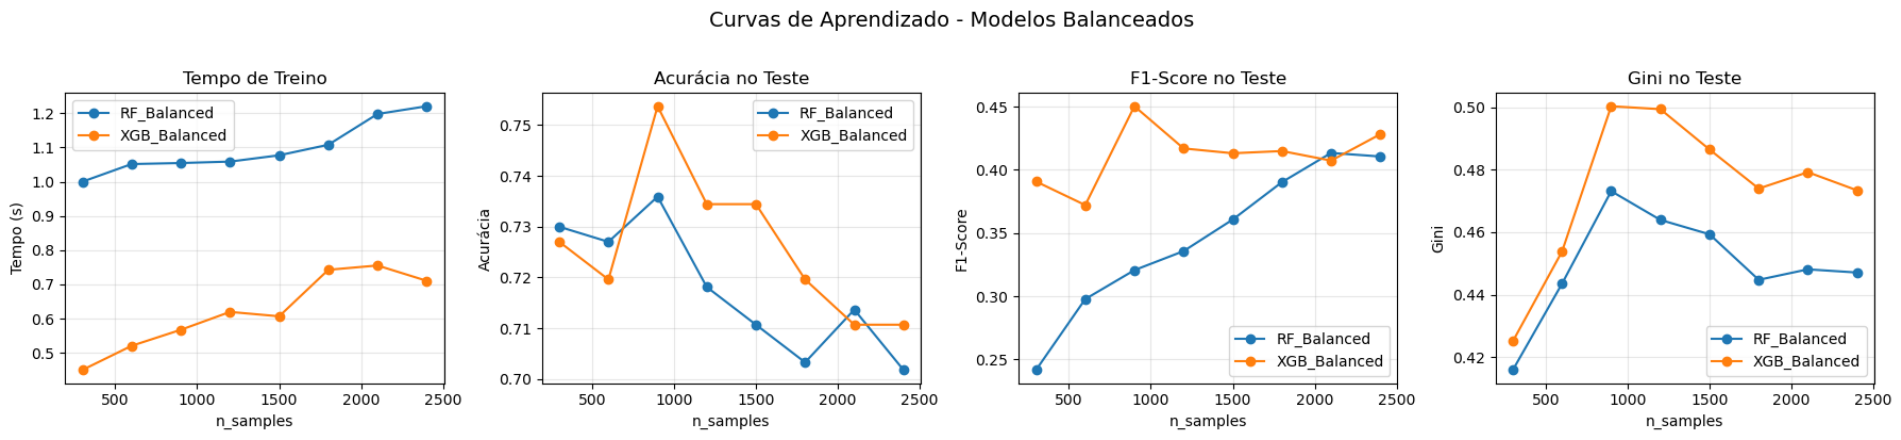

Implicações: A curva de F1-Score crescente indica que ambos os modelos se beneficiam do aumento de dados, especialmente para identificação da classe minoritária. O XGBoost, apesar da maior oscilação em amostras intermediárias, demonstra melhor desempenho global quando treinado com o conjunto completo, aliando eficiência computacional e métricas superiores.

Importância das Variáveis

Análise de Feature Importance

O modelo Random Forest foi utilizado para quantificar a contribuição de cada atributo acústico na previsão da popularidade.

Atributos Mais Relevantes

- **instrumentalness**
- **loudness**
- **acousticness**
- **speechiness**

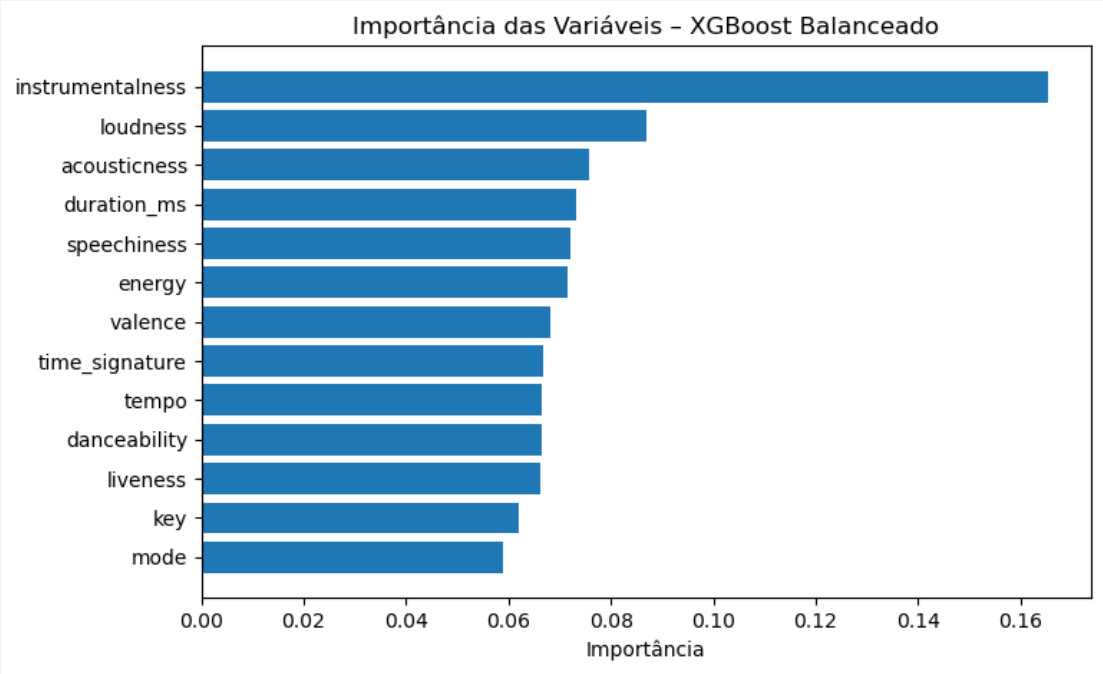

Conclusões da Classificação

Capacidade Preditiva

Os modelos demonstraram um **desempenho razoável** na previsão da popularidade, indicando que os atributos acústicos são **fatores relevantes** para determinar o sucesso de uma música.

Estabilidade dos Resultados

Os resultados foram **estáveis** e consistentes, sugerindo que os modelos são **generalizáveis** para dados não vistos, o que reforça a robustez da abordagem.

Limitações do Estudo

- A definição binária de popularidade (acima de 70) é uma **simplificação** que pode não capturar toda a complexidade do fenômeno.
- Fatores externos como marketing, artista famoso e contexto cultural não foram considerados no modelo.
- A qualidade e representatividade do dataset podem influenciar a generalização dos resultados.

Clusterização de Músicas

1 Método

- Utilização do algoritmo **K-Means** para agrupamento não supervisionado.
- Objetivo: Agrupar músicas com **características acústicas similares**.
- Abordagem centróide-baseada para descoberta de padrões.

2 Variáveis

- Clusterização realizada com **apenas variáveis numéricas**.
- Exclusão de variáveis categóricas para homogeneidade.
- Foco em atributos acústicos mensuráveis.

3 Pré-processamento

- **Padronização** é crucial para o K-Means.
- Aplicação de PCA com 6 componentes principais, preservando aproximadamente 85–90% da variância total dos dados.
- O PCA foi utilizado para:
  - Reduzir a dimensionalidade,
  - Mitigar correlação entre variáveis,
  - Melhorar a visualização e interpretação dos clusters.

  Obs.: Para visualização, os clusters foram projetados nos dois primeiros componentes principais, enquanto o K-Means foi ajustado utilizando os 6 componentes do PCA.

Escolha do Número de Clusters

1 **Método do Cotovelo**

- Análise da variação da **soma dos quadrados intra-cluster** (*inertia*)
- Observação do ponto de **inflexão** (cotovelo)
- Identifica o número ótimo de clusters

2 **Métrica de Apoio**

- **Silhouette Score** valida a qualidade
- Mede **coesão** e **separação** dos clusters
- Valores entre -1 e 1 (maior é melhor)

3 **Escolha Final**

- Valor ótimo determinado: **k = 3**
- Consenso entre Elbow e Silhouette
- Interpretabilidade dos grupos

```
k = 3 | Silhouette Score = 0.249
k = 4 | Silhouette Score = 0.234
k = 5 | Silhouette Score = 0.235
```

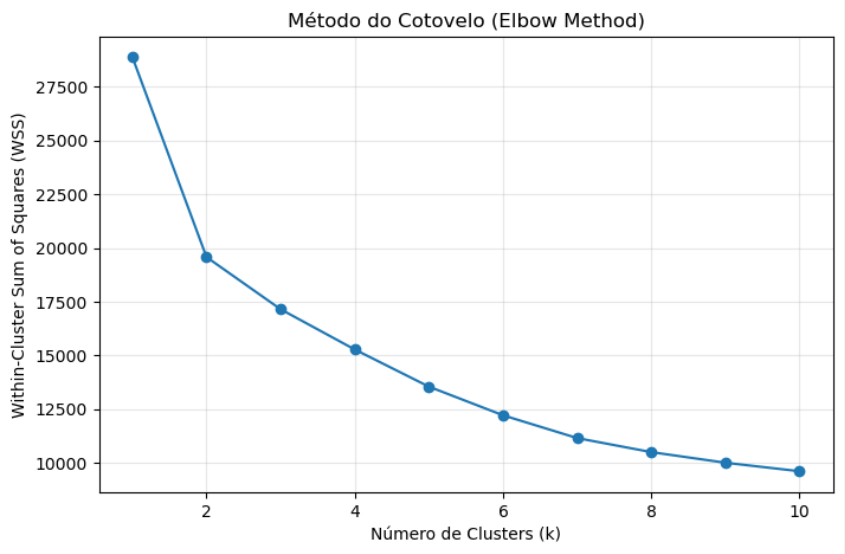

Redução de Dimensionalidade e Visualização

O que é PCA

PCA (Principal Component Analysis) é uma técnica de redução de dimensionalidade que transforma um conjunto de variáveis correlacionadas em um novo conjunto de variáveis não correlacionadas chamadas componentes principais.

Componentes Principais

- Os **dois primeiros componentes principais** explicam uma grande parte da variância original dos dados.
- Essa redução permite **visualização eficaz** em um espaço bidimensional.
- Mantém a **estrutura dos dados** e as relações entre observações.

Benefício para Visualização dos Clusters

A projeção dos dados nos dois primeiros componentes do PCA permite visualizar claramente como os clusters se distribuem no espaço reduzido. Essa visualização é fundamental para interpretar a separação entre grupos e validar a qualidade da clusterização realizada pelo K-Means.

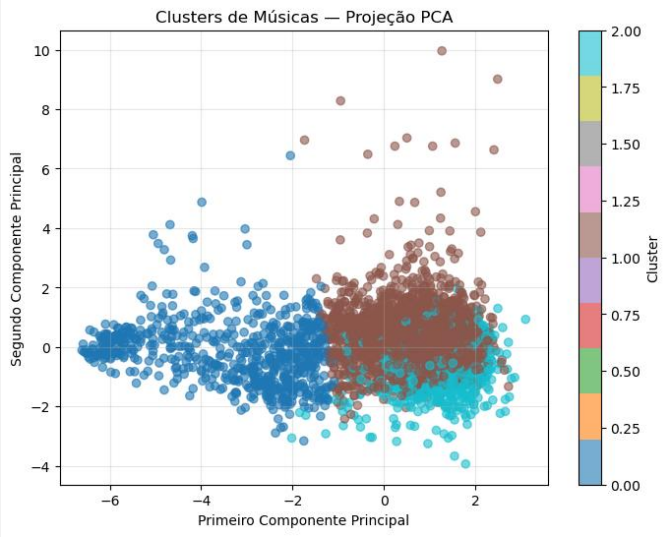

Interpretação dos Clusters

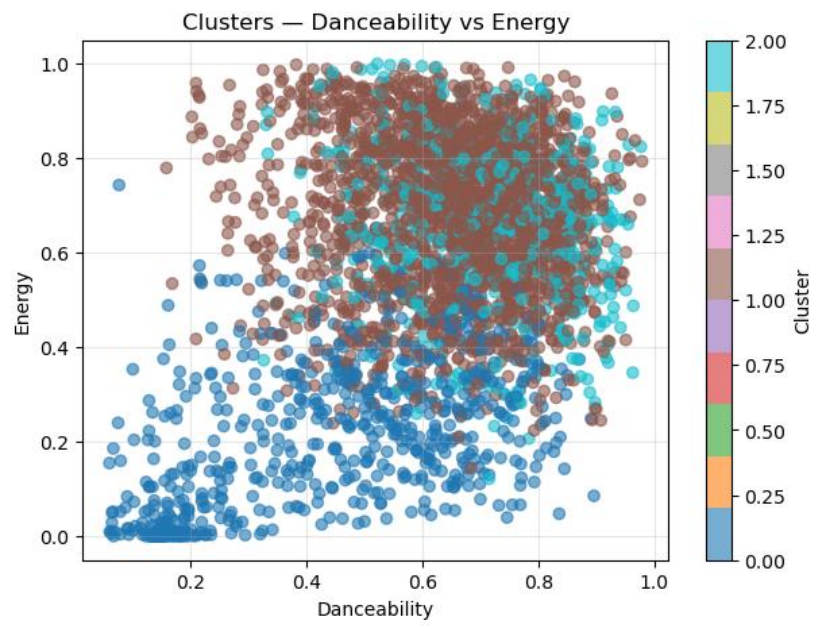

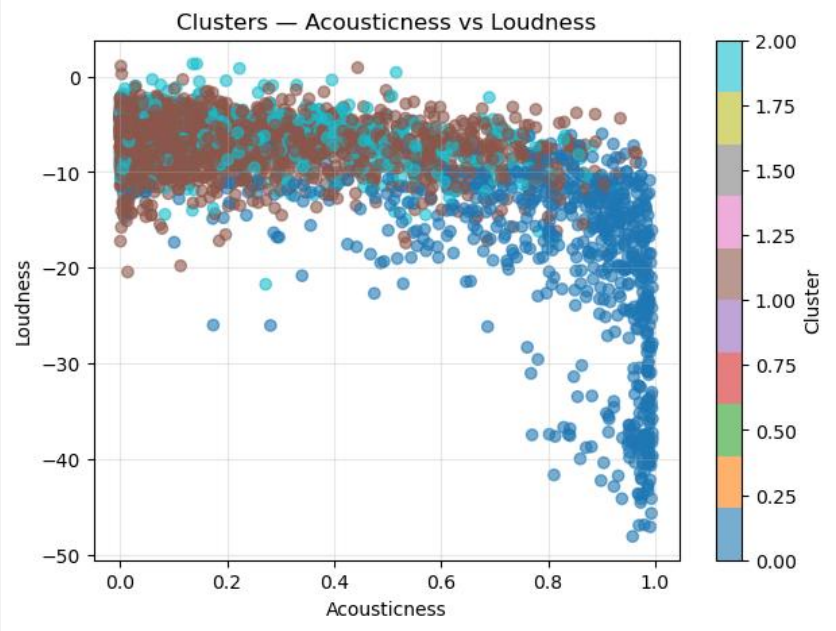

Os clusters apresentam perfis acústicos distintos, especialmente em energia, danceability, loudness e acousticness, indicando a existência de grupos de músicas com características similares.

Perfis, Conclusões e Futuro

Perfis dos Clusters

Os três grupos identificados apresentam diferenças claras em atributos como **energy**, **danceability**, **acousticness** e **loudness**, evidenciando perfis musicais distintos e bem caracterizados.

Respostas Finais

1. Os atributos acústicos são **relevantes** para a popularidade.
2. A popularidade é **previsível** com desempenho razoável.
3. Existem **três grupos** de músicas com características similares.

cluster	energy	tempo	danceability	loudness	liveness	valence	speechiness	instrumentalness	acousticness	duration_ms
0	0.212940	107.853980	0.434456	-19.570430	0.131413	0.213301	0.052498	0.707933	0.819919	181727.972303
1	0.683638	120.708284	0.653850	-6.808113	0.170781	0.546959	0.064104	0.091097	0.216344	218084.713470
2	0.655495	123.198015	0.712352	-6.797699	0.204345	0.566144	0.287813	0.044341	0.273795	190063.400344

Os clusters identificados refletem diferentes perfis musicais com base em características acústicas. Observa-se um grupo de faixas mais acústicas e instrumentais, com menor energy e loudness; um grupo mais energético e dançante, com valores elevados de energy, danceability e loudness; e um grupo intermediário, que combina características dos dois extremos. As projeções nos planos Danceability × Energy e Acousticness × Loudness evidenciam a separação desses perfis e reforçam a coerência da clusterização.

Desafios Encontrados

- Definição do número ótimo de clusters
- Presença de valores ausentes no dataset
- Escolha do melhor modelo de classificação

Melhorias Futuras

- Incorporação de dados textuais (letras)
- Uso de modelos de *deep learning*
- Análise temporal de tendências musicais